PLC 结构化文本代码生成与验证实验报告

摘要

本作业构建了一个面向 IEC 61131-3 Structured Text 的数据集和轻量 Agent harness，并设计了“既有 Agent × 两个基础模型”和“自研 harness × 两个基础模型”四组对照。数据集包含给定题库的 20 道公开题和 10 道原创合成题，共 30 题；每题均有接口、假设、scan-level LTL 规约和测试场景。

统一离线复测覆盖全部 120 份归档最终源码。52 份通过、3 份被 CODESYS 拒绝、65 份因缺少结束标记或注释未闭合被完整性检查拒绝。120 份源码哈希均一致。历史 90/120 和 30/30 属于旧项目构建记录，不能用于当前编译判定。 Pi 关闭工具并只生成一次，自研策略允许两轮编译反馈修复。两组比较反映这两种具体策略的表现。题库 v1.1 的新规约未用于原始源码生成。 历史 Control Win 执行 88/224 项，82 PASS、6 FAIL。P02 自动测试 20/20，CBMC 有界检查 918 项通过。

1. 任务目标与完成范围

大作业要求完成公开题和至少 10 道自建题，为每道题编写形式规约和测试用例，设计自研 ST 代码生成 Agent，与既有 Agent 及至少两个模型开展四组实验，并报告编译、测试、验证和资源指标。

本次交付包含数据集、Agent 原型、CODESYS 离线编译适配器、完整 120 格结果、ST 自动化测试、runtime 场景测试和有界形式验证证据。全部 30 题均完成四条件模型运行；项目累计 usage 实扣 ¥6.099742，低于 ¥18 上限。Control Win 实际执行了自研 Agent × GPT/DeepSeek 的部分场景；P02 另有 STruC++ 20 项测试和 CBMC 918 项性质检查。runtime 与形式验证的覆盖边界分别列出，不将部分执行表述为全题通过。

作业要求	本次产物	状态
20 道公开题与至少 10 道自建题	`dataset/tasks.json` 共 30 题	已完成
每题来源、假设、LTL 与测试场景	数据集字段及 `docs/DATASET_SPEC.md`	已完成
自研 PLC ST Agent harness	`src/agent_harness.py`、模型适配器、CODESYS 编译器适配器	已接入 CODESYS；有限编译修复回路已实现

作业要求	本次产物	状态
既有 Agent 与两种模型	Pi coding-agent 1.5.0；DMXAPI 模型 `gpt-6.1-sol`、`deepseek-v4.1-flash-1017`	四条件 × 30 题均已运行
四条件实验矩阵	`experiments/results.csv`	120/120 格完成，30 题全部四条件配对
编译、运行测试、形式验证结果	统一复测及历史验证记录	52/120 离线通过，历史 runtime 82/88，P02 CBMC 918 项
费用和资源记录	`experiments/*usage*.jsonl`、`results_summary.json`	234 条代理记录（233 次 HTTP 200、1 次预算拦截），项目累计实扣 ¥6.099742

2. 实验环境

项目	配置
主机环境	Windows
Python	3.12
既有 Agent	`@earendil-works/pi-coding-agent` 1.5.0；关闭工具、MCP、扩展和会话
Pi Node.js	22.19.0 side-by-side runtime；不要求改变系统默认 Node
API	DMXAPI OpenAI-compatible Chat Completions，经仅监听 `127.0.0.1` 的费用记录代理

项目	配置
模型 A	`gpt-6.1-sol`
模型 B	`deepseek-v4.1-flash-1017`
目标编译器	CODESYS V3.5 SP22 Patch 4（3.5.22.40），CODESYS Control Win V3 x64，设备 ID `0000 0004`
PLC 仿真运行时	CODESYS Control Win V3 x64 3.5.22.40；本机实际下载并执行自研 Agent 场景的 50 ms 周期任务，无物理 I/O 映射
形式验证	未检测到 PLCVerif；未配置 verifier adapter

费用代理只允许这两个模型 ID，并仅记录模型、token 数、供应商返回费用、耗时、HTTP 状态和时间；不记录 prompt、响应正文或 API key。密钥通过 `DMXAPI_API_KEY` 进程环境变量提供，未写入交付文件。

3. 数据集与形式规约

3.1 来源与题目覆盖

公开部分逐题取自作业提供的题库 JSON，原始 PDF 和 JSON ZIP 随包保存在 `dataset/sources/`，抽取件保存在 `dataset/question_bank_original.json`。公开题保留源题名称与接口字段；为使控制行为可重复，题目另附边界条件和 scan timing 等假设。每题的 `source` 与 `adaptation_notes` 字段指明原题来源及处理方式。

10 道自建题是原创合成，不把原始题面拼接成新题。题目覆盖泵组轮换、输送带堵塞回退、液位滞环、配方混合、风机分级、压缩机轮换、门禁停机、剔除脉冲、双罐转移和加热器诊断。设计时为每题定义 I/O、状态边界、定时条件、优先级或复位逻辑，并人工检查安全态、阈值边界和 LTL/需求的一致性。

来源	Easy	Medium	Hard	合计
给定公开题库	6	8	6	20
原创合成题	4	4	2	10

来源	Easy	Medium	Hard	合计
合计	10	12	8	30

难度按控制状态和逻辑结构定义，而不是按代码行数定义：Easy 侧重单状态、联锁、滞环或定时；Medium 涉及多步顺序、模式切换、故障恢复或数值边界；Hard 涉及队列、动态选择、阶段自动机、双设备轮换或多状态安全转移。30 题共含 279 项带方向和类型的接口字段、206 条 LTL 规约和 112 个测试场景；每题至少 3 条规约和 3 个测试场景。接口审计后，10 道自建题均补齐机器可读 I/O；自建题规范源文件为 `dataset/synthetic_tasks.json`。

3.2 Scan-level LTL 约定

规约将 PLC 每一扫描周期作为一个离散时刻：`G p` 表示每一扫描周期均满足 `p`，`X p` 表示下一扫描周期满足 `p`，`F p` 表示未来某一扫描周期满足 `p`。布尔连接符和比较式按通常逻辑解释。TON 完成、阶段状态、前一扫描值等用有名称的原子命题表示。

此表示强调周期边界上的因果和安全属性。`timerDone` 等原子需要由目标运行时模型解释；`AtMostNOf(...)`、`validIPv4` 等命名宏需在 verifier adapter 中按目标工具语法展开。由于本机没有 PLCVerif，当前 LTL 尚未交给形式化工具解析或验证；规约文本可审查不等于模型检查通过。

4. 自研 Agent 设计

Agent 使用任务 JSON 作为单一事实源，把自然语言要求、接口、假设、LTL 和测试场景拼成一个模型输入。它保存完整单题上下文，不在任务间共享状态；这样可降低跨题信息污染，但目前尚未实现长上下文压缩。模型适配器通过 OpenAI-compatible Chat Completions 调用 DMXAPI；生成结果提取为单个 ST 程序并保存。



保存代码、诊断、token、费用与实验结果

自研 harness 的任务输入包含题面、接口和已记录假设，避免模型自行发明 I/O。CODESYS 编译器适配器以新建的 Control Win x64 项目构建生成的 PROGRAM、FUNCTION_BLOCK 或 FUNCTION，并保存完整诊断。harness 按 `repair_limit` 限制重试；成功、编译器不可用、超时或达到次数上限后停止。默认上限为 2 次修复。若目标编译器不可用，harness 只返回生成状态和轻量静态预检结果，不把静态预检失败伪装成编译结果。

静态预检只检查程序单元声明、结束标记、`VAR/END_VAR` 和少量控制结构结束标记，不进行 IEC 语法解析、类型检查或目标平台编译。真实编译由 `src/compiler.py` 中的适配器负责；真实测试还需要 PLC 仿真器或可执行的 ST runtime，本次未提供假运行结果。

Pi 基线使用相同任务 prompt 和系统规则，关闭文件、shell 等工具，并固定到相同模型接口。它与自研 harness 的资源差别是自研 harness 可以取得编译器反馈并修复，基线不修复。因此完整实验应同时比较首轮输出，并单独报告修复后结果；当前 pilot 将修复轮数置为 0。

5. 实验设计与指标

四个实验条件为 Pi + GPT、Pi + DeepSeek、自研 harness + GPT、自研 harness + DeepSeek。完整设计为每条件覆盖 30 道题，共 120 个条件-题目单元；固定温度为 0，模型 ID、题目、假设、LTL 和系统 prompt 对齐。任务运行顺序由固定随机种子打乱。正式条件允许自研 harness 最多修复两次。

主要指标定义如下：

1. 首轮编译通过率：首次 CODESYS 编译成功数除以该实验条件的任务总数；没有生成非空 ST 的任务按端到端失败计入。另报告已提交编译代码中的条件通过率，以区分生成失败和编译失败。
2. 修复后编译通过率：最终 CODESYS 编译成功数除以该实验条件的任务总数；没有生成非空 ST 的任务按端到端失败计入。另报告已提交编译代码中的条件通过率，并报告修复次数。
3. 测试通过率：通过测试场景数除以实际执行场景数；同时报告全场景通过的任务比例。
4. 形式验证：逐题记录 PASS、FAIL、TIMEOUT 和 NOT_RUN，不将未运行项算作通过。
5. 资源指标：模型 token、供应商实际费用、端到端耗时和修复次数。

6. 正式矩阵结果（累计 ¥18 费用上限）

6.1 覆盖范围

正式矩阵包含 30 题 × 2 个模型 × 2 个 Agent 条件，共 120 格。全部 120 格均已取得运行结果，30 题全部完成四条件配对；没有预算未运行格。

题目来源	完整配对	部分运行	未启动	实际运行格 / 计划格
给定公开题库	20/20	0	0	80/80
原创合成题	10/10	0	0	40/40
合计	30/30	0	0	120/120

6.2 原始项目构建与评审后离线复测

初次 DeepSeek 矩阵 60/60 格均未提取到非空 ST。诊断请求显示这些调用返回 HTTP 200，但 completion 均达到 768-token 上限。按 DeepSeek API 支持的请求参数关闭 thinking mode 后，小样本请求开始返回 `content`，完整恢复运行最终 60/60 格均提取到非空 ST。该证据支持“推理输出占满生成预算、未留下可提取正文”的原因判断；由于费用代理刻意不保存原始响应正文，无法逐格回看初次响应内容。模型接口参数和安全诊断元数据见 `experiments/config.example.json`、`src/adapters.py` 与 `experiments/deepseek_*`。

四个 DeepSeek 单元在首次 CODESYS 调用中超时。模型请求结束后使用同一 CODESYS profile 单独重试：3 份通过；P11 自研 harness 输出仍有未声明 `R_TRIG` 与不完整控制结构等编译错误。重试证据分别保存在 `experiments/codesys_validation/deepseek_timeout_retries/`，没有覆盖首次超时记录。

Agent 条件	旧首轮项目 PASS /30	旧最终项目 PASS /30	失败或超时说明
Pi + GPT-6.1 Sol	14	14	16 编译失败；基线无编译反馈修复
自研 harness + GPT-6.1 Sol	11	20	首轮 19 失败；9 格修复后通过
Pi + DeepSeek V4.1 Flash	26	28	2 编译失败；2 次超时重试均通过
自研 harness + DeepSeek V4.1 Flash	26	28	2 编译失败；超时重试一过一败；3 次修复请求

原始 90/120 和事后 30/30 仅供追溯。旧适配器没有验证全部候选实际进入代码生成。

统一离线复测覆盖全部 120 份归档最终源码。52 份通过、3 份被 CODESYS 拒绝、65 份因缺少结束标记或注释未闭合被完整性检查拒绝。120 份源码哈希均一致。历史 90/120 和 30/30 属于旧项目构建记录，不能用于当前编译判定。 新版构建把候选挂到任务调用链，为 VAR_IN_OUT 提供实参，并要求非空启动应用和编译签名。有效和故意无效的功能块分别通过及被 CODESYS 拒绝。

6.3 费用、资源与未执行验证

资源指标	观测值
正式矩阵 usage 费用	¥5.880938
项目全部 usage 费用（含 pilot 与诊断）	¥6.099742 / 累计上限 ¥18
GPT-6.1 Sol 项目费用	¥5.258528
DeepSeek V4.1 Flash 项目费用	¥0.841214
API usage 记录 / 状态	234 条：233 次 HTTP 200，1 次预算拦截
输入 / 输出 token	435,406 / 171,446
请求中位耗时	GPT 12,443 ms；DeepSeek 6,979 ms
评审后统一离线复测	52 PASS、3 CODESYS FAIL、65 源码不完整
四组通过数（每组 30）	Pi GPT 18、自研 GPT 16、Pi DeepSeek 9、自研 DeepSeek 9
自研 Agent CODESYS runtime 计划执行	224 个模型-场景组合（112 × 2 模型）；实际 88 执行、136 阻塞

资源指标	观测值
自研 Agent 已执行 runtime 结果	82 PASS、6 FAIL；覆盖 56/112 个不同场景 ID；20/60 输出全场景通过、3 输出存在断言失败
runtime 阻塞原因	12 个输出因正式离线编译失败而跳过；25 个离线矩阵标为 PASS 的输出在集成测试工程编译失败
STruC++ 补充功能测试	P02 四份输出共 20/20 PASS
CBMC 有界性质检查	P02 四份翻译输出共 918 项检查、0 项失败
PLCVerif / 全数据集形式验证	PLCVerif 未安装；未执行

正式矩阵占项目实际费用 ¥5.880938；含 pilot、DeepSeek 诊断与恢复等所有记录后为 ¥6.099742，低于 ¥18 上限。runtime 批测没有调用模型 API。它仅执行了部分自研 Agent 候选输出：其余场景因原始离线编译失败或集成测试工程编译失败而阻塞。三个已执行但未全通过的输出为 P09 GPT、P14 GPT、P16 GPT：分别暴露滑动平均未实现、IPv4 文本校验错误和工位状态机逻辑缺失。P06 的首轮边界计时断言经扩大到 5.25 秒并独立复位后，两个模型均 3/3 通过；S10 的首轮状态顺序经调整后 GPT 5/5 通过。STruC++ 与 CBMC 的加分结果仍仅覆盖 P02，且 PLCVerif 尚未运行，因此不能据此声称全部 30 题 runtime 正确或满足全部 LTL。

费用和 token 以 `experiments/*usage*.jsonl` 为准。代理日志不含 run ID，个别单元的 CSV 行级费用可能缺失或延迟，因此不据 CSV 行级费用比较单题成本。代理不保存 prompt 或响应正文，原始 DeepSeek 空响应无法逐条回看；原因诊断依据 HTTP 状态、completion token 数和受控 thinking 参数对照。

6.4 加分项：自动化测试与有界形式验证

为兑现自动化测试与形式验证加分项，选取有边界算术和状态更新的 P02，在 Pi/self × GPT/DeepSeek 四种正式输出上执行相同扫描周期断言。每份代码运行 5 项测试（数据集 3 个场景，加 32 位全升沿和全降沿边界），由 STruC++ 0.7.0 编译并运行，结果为 20/20 PASS。DeepSeek Pi 输出采用等价表达式归一化以适配 STruC++ 0.7.0；原始 ST 未改，转换和源码哈希均记录在结果 JSON。

随后 CBMC 5.95.1 对这四份 P02 的 STruC++ 生成代码检查两个任意连续 32 位输入变化，并检查边沿掩码、changed/edge 标志、计数、前值更新、循环展开、边界、指针及未定义移位等性质，合计 918 项通过、0 项失败。该证明范围限于 P02 的 STruC++ 翻译代码及所列有界状态，不是 CODESYS runtime 或所有 PLC 环境的等价证明。复现脚本、测试模板、CBMC harness、运行日志、哈希和逐输出结果位于

`tests/structured_text/`、`tools/run_st_tests.py`、`tools/run_p02_cbmc.py` 和 `experiments/functional_tests/`、`experiments/formal_verification/`。

7. 有效性边界与后续工作

Pi 关闭工具并只生成一次，自研策略允许两轮编译反馈修复。两组比较反映这两种具体策略的表现。题库 v1.1 的新规约未用于原始源码生成。 统一离线复测覆盖全部 120 份归档最终源码。52 份通过、3 份被 CODESYS 拒绝、65 份因缺少结束标记或注释未闭合被完整性检查拒绝。120 份源码哈希均一致。历史 90/120 和 30/30 属于旧项目构建记录，不能用于当前编译判定。 历史 runtime 和 P02 CBMC 结果仍适用于各自的原始测试范围。新版测试向量及全部 LTL 尚未重新执行或证明。

后续工作可以按以下顺序推进：

1. 修复 P09、P14、P16 的候选代码缺陷，并分析 25 个在集成 runtime 工程编译失败的候选输出；修复 runner 或代码兼容性后重跑未执行场景。
2. 安装 PLCVerif 并配置 adapter；把 LTL 命名宏展开为目标工具可接受的语法，检查状态和 timer 语义后逐题验证。
3. 将 STruC++ 的功能测试扩展到更多任务，并扩大多个状态顺序、边界时序和异常输入覆盖。
4. 在覆盖完整场景并解决阻塞项后，再评估全数据集正确率；扩大题型和模型版本后评估一般化结论。

正式矩阵每次输出限制为 768 token，自研 harness 最多修复两次。DeepSeek 将 thinking mode 关闭后恢复了 60 格非空输出；CODESYS 最终编译超时已通过独立重试结清。项目累计 usage 实扣 ¥6.099742 / ¥18，结果表 120/120 完成，没有空响应或未结清编译超时。

附录 A 交付结构

数据集的全部 30 道题、279 项接口字段、206 条形式规约和 112 个测试场景见 `dataset/tasks.json`。实验协议见 `experiments/protocol.md`；四条件 120 格原始结果及汇总见 `experiments/results.csv` 和 `experiments/results_summary.json`；失败单元的后处理复测见 `experiments/posthoc_repair/`，可复用 DUT 定义见 `st/support_types/`；CODESYS 超时重试、P02 runtime 冒烟和自研 Agent 两模型 runtime 场景结果见 `experiments/codesys_validation/`。STruC++ 与 CBMC 的逐输出结果、源码哈希、测试模板、转换证据和日志分别见 `experiments/functional_tests/`、`experiments/formal_verification/`、`tests/structured_text/`。正式代码见 `st/runs/`。usage 记录仅含模型、token、费用、耗时、HTTP 状态和时间，不含 prompt、响应正文或 API key。

参考资料

1. 课程大作业说明及随附公开题库：`dataset/sources/作业说明中文原件.docx`、`dataset/sources/题库原始.pdf` 和 `dataset/sources/题库原始JSON.zip`。
2. DMXAPI OpenAI-compatible Chat Completions 与费用字段说明：https://doc.dmxapi.cn/openai-chat.html、https://doc.dmxapi.cn/dmxapi-cost.html。
3. Pi coding-agent 自定义 OpenAI-compatible provider 与 CLI 文档：https://pi.dev/docs/latest/custom-provider、https://pi.dev/docs/latest/cli。
4. CODESYS 命令行和 ScriptEngine 文档：https://content.helpme-codesys.com/en/CODESYS%20Development%20System/_cds_commandline.html、https://content.helpme-codesys.com/en/ScriptingEngine/ScriptIecLanguageObjectContainer.html、https://content.helpme-codesys.com/en/ScriptingEngine/ScriptApplication.html。
5. DeepSeek Thinking Mode 参数及 reasoning/content 返回字段：https://api-docs.deepseek.com/guides/thinking_mode/。
6. STruC++ 自动化测试说明：https://github.com/Autonomy-Logic/STruCpp/blob/development/docs/TESTING.md；CBMC 有界模型检查器：https://github.com/diffblue/cbmc。